==========

Character Preservation Benchmark — Literature & Typography

Document ID: 06_literatura

Domain: Literature / Typography

Language: es

Version: 1.0

Description: Documento sintético de benchmark para evaluación de parsers PDF en el contexto de arquitecturas RAG. Contiene casos de prueba controlados con símbolos tipográficos y caracteres literarios.

Date: 2024-01-01

==========

SECCIÓN 1 — TEXTO DE CONTROL

La literatura es el arte de la escritura. Sus géneros principales incluyen la narrativa, la poesía, el teatro y el ensayo. A través de los siglos, los escritores han desarrollado recursos estilísticos y convenciones tipográficas que enriquecen la comunicación escrita.

La tipografía estudia el diseño y uso de los tipos de letra. Una buena tipografía mejora la legibilidad y la estética del texto. Los procesadores de texto modernos ofrecen acceso a una amplia variedad de caracteres especiales que enriquecen la escritura.

Este párrafo contiene solo texto convencional en español. No hay caracteres especiales salvo los propios de la ortografía española: tildes, ñ, ü, y signos de puntuación estándar como coma, punto, punto y coma, dos puntos, guión.

SECCIÓN 2 — CARACTERES AISLADOS

2.1 Comillas tipográficas

Símbolo	Nombre	Unicode
«	Comilla francesa de apertura	U+00AB
»	Comilla francesa de cierre	U+00BB
"	Comilla inglesa de apertura	U+201C
"	Comilla inglesa de cierre	U+201D
'	Comilla simple de apertura	U+2018
'	Comilla simple de cierre	U+2019
‹	Comilla francesa simple apertura	U+2039
›	Comilla francesa simple cierre	U+203A
"	Comillas dobles ASCII (rectas)	U+0022
'	Comilla simple ASCII (recta)	U+0027

2.2 Guiones y rayas

Símbolo	Nombre	Unicode	Uso
-	Guión corto (hyphen)	U+002D	Separación silábica, compuestos
–	Guión medio (en dash)	U+2013	Rangos: 1990–2000, etc.
—	Raya (em dash)	U+2014	Inciso, diálogo
—	Línea horizontal	U+2015	Diálogo (alternativa)
-	Guión tipográfico	U+2010	Versión tipográfica del guión

2.3 Puntuación especial

Símbolo	Nombre	Unicode

--------|--------------------------|--------

… | Puntos suspensivos (elipsis) | U+2026

· | Punto volado / interpunto | U+00B7

¡ | Signo de exclamación inverso | U+00A1

¿ | Signo de interrogación inverso | U+00BF

§ | Sección | U+00A7

¶ | Pilcrow / Párrafo | U+00B6

† | Daga (nota al pie) | U+2020

‡ | Doble daga (nota al pie) | U+2021

* | Asterisco | U+002A

• | Bullet / Viñeta | U+2022

2.4 Espacios especiales

Nombre | Unicode | Descripción

---------|----------|---------

Espacio de no separación | U+00A0 | No permite salto de línea aquí

Espacio fino | U+2009 | Espacio más estrecho que normal

Espacio de puntuación | U+2008 | Espacio del ancho de un signo ,

Espacio em | U+2003 | Espacio del ancho de una M

Espacio en | U+2002 | Espacio del ancho de una N

2.5 Ligaduras

Símbolo | Nombre | Unicode

--------|----------|--------

fi | Ligadura fi | U+FB01

fl | Ligadura fl | U+FB02

ff | Ligadura ff | U+FB00

ffi | Ligadura ffi | U+FB03

ffl | Ligadura ffl | U+FB04

æ | ae (letra) | U+00E6

œ | oe (letra) | U+0153

2.6 Signos tipográficos comerciales

Símbolo | Nombre | Unicode

--------|----------------------|--------

© | Copyright | U+00A9

® | Marca registrada | U+00AE

™ | Marca comercial | U+2122

2.7 Diacríticos comunes en español y otras lenguas latinas

Símbolo | Nombre | Unicode

--------|--------------------------------|--------

á | a con acento agudo | U+00E1

é | e con acento agudo | U+00E9

í | i con acento agudo | U+00ED

ó | o con acento agudo | U+00F3

ú | u con acento agudo | U+00FA

ü | u con diéresis | U+00FC

ñ | eñe | U+00F1

à | a con acento grave | U+00E0

è | e con acento grave | U+00E8

â | a con acento circunflejo | U+00E2

ê | e con acento circunflejo | U+00EA

ô | o con acento circunflejo | U+00F4

ç | c cedilla | U+00E7

SECCIÓN 3 — CARACTERES DENTRO DE TEXTO

3.1 Comillas francesas

Las comillas francesas se usan en muchos países hispanohablantes y en Francia:

«Este es un texto entre comillas francesas.»

«El maestro dijo: "La vida es un misterio", y siguió su camino.»

En algunos países se prefiere el estilo: «Texto con 'comilla interna'».

En otros se usa: «Texto con "comilla interna"».

3.2 Comillas inglesas

En inglés y en textos académicos en español se usan comillas inglesas:

"This is a quote in English."

"The professor said, 'never give up,' and left the room."

Texto con comillas inglesas en español:

"La novela comenzó con una frase memorable."

El narrador describió "una tarde de verano calurosa" en pocas palabras.

3.3 Raya de diálogo

La raya tipográfica (—) se usa para indicar diálogo directo:

—¿Dónde estabas? —preguntó ella.

—No lo sé —respondió él.

—¿Cómo puede ser que no lo sepas?

También se usa para incisos:

El viajero —exhausto tras días de caminata— llegó al pueblo al anochecer.

La decisión —aunque difícil— era la única posible.

3.4 Guión medio para rangos

La guerra duró entre 1939–1945.

El horario de atención es 9:00–17:00.

Las páginas 45–78 contienen el análisis.

El período 1810–1824 fue fundamental para la independencia.

3.5 Puntos suspensivos

El símbolo … (U+2026) es un único carácter, diferente de tres puntos separados (...) que son tres caracteres ASCII.

Ejemplos de uso:

No sabía qué decir…

El camino continuaba… y continuaba… sin fin aparente.

La respuesta era «sí… pero con condiciones».

3.6 Signos de admiración e interrogación

En español se usan signos de apertura y cierre:

¡Qué sorpresa!

¿Por qué?

¡¿Cómo pudiste?!

¿¡De verdad!?

Combinaciones:

¡Increíble! No podía creerlo.

¿Sabes lo que significa esto?

¡¿Pero qué estás diciendo?!

3.7 Apóstrofe tipográfico vs ASCII

El apóstrofe tipográfico es ' (U+2019, comilla simple de cierre).
El apóstrofe ASCII es ' (U+0027, comilla simple recta).

En textos formales se usa el tipográfico:
It's a beautiful day. (con U+2019)
L'homme (francés, con U+2019)
D'accord (francés, con U+2019)

En programación y texto plano se usa el ASCII:
it's (con U+0027)
don't (con U+0027)

3.8 Ligaduras en texto

Las ligaduras son combinaciones de letras que se fusionan tipográficamente.
Las más comunes son fi (fi), fl (fl), ff (ff), ffi (ffi), ffl (ffl).

En texto normal: "difficulty", "sufficient", "official", "affluent"
Con ligaduras Unicode: "difficulty", "sufficient", "official", "affluent"

La mayoría de las fuentes de calidad aplican ligaduras automáticamente
mediante características OpenType, sin que el texto fuente contenga
los caracteres de ligadura Unicode.

3.9 Punto volado (interpunto)

El interpunto · (U+00B7) tiene varios usos:
- Separación de elementos en catalán: Paral·lel, col·legi

- Indicación de producto en matemáticas: a · b

- Puntos de hidratación en química: $CuSO_4 \cdot 5H_2O$

- Separación en nomenclatura: Homo·sapiens (estilo tipográfico)

SECCIÓN 4 — COMBINACIONES DE SÍMBOLOS

4.1 Texto literario con múltiples tipos de comillas

«El poeta escribió: "No hay noche tan oscura / que no amanezca al fin".»

«Aquí —dijo la profesora— encontramos la 'paradoja fundamental'.»

El narrador describió «una ciudad que dormía» y añadió: "Era extraño."

4.2 Texto con todos los tipos de puntuación especial

¡Sorprendente! El resultado fue… inesperado. ¿Quién podría haberlo previsto?

—Nadie —respondió él—. Absolutamente nadie.

La conclusión era clara: «Todo había cambiado» para siempre…

4.3 Mezcla de comillas y rayas

«—¿Recuerdas aquella tarde? —preguntó María.

—Claro que sí —respondió Juan—. Fue en 1985, o quizás en 1986…

—"Era un verano extraño", escribiste después. ¿Lo sigues pensando?»

4.4 Rangos y referencias tipográficas

Ver páginas 15–47 para el análisis completo.

El período 1492–1600 marcó el Renacimiento español.

Las secciones §1–§5 contienen la parte teórica.

Las notas † y ‡ al pie de página explican los casos especiales.

4.5 Copyright y marcas

© 2024 Ejemplo Corporation. Todos los derechos reservados.

® es una marca registrada de la empresa.

™ indica marca comercial no registrada.

Esta guía es © Autor, 2020–2024.

SECCIÓN 5 — EXPRESIONES COMPLEJAS

5.1 Fragmento narrativo con puntuación tipográfica compleja

El anciano filósofo —que había vivido noventa años entre libros y silencios— levantó la vista del manuscrito y dijo: «La verdad… ¿qué es la verdad?»

¡Nadie respondió! El silencio era la única respuesta posible. María pensó: "Quizás él tampoco lo sabe." Y así permanecieron, inmóviles, durante lo que pareció una eternidad…

La nota al pie† señalaba: "Este pasaje es deliberadamente ambiguo."
Una segunda nota‡ añadía: "Compare con el diálogo del capítulo VII."

5.2 Cita académica formal

Según García Márquez (1967)†, «la realidad latinoamericana supera con creces a la ficción más elaborada». Esta afirmación —controvertida en su momento—

encontró eco en toda una generación de críticos literarios.

El crítico respondió: "La obra de García Márquez representa un 'giro copernicano' en la narrativa hispanoamericana."‡

† Referencia inventada para fines de este benchmark.
‡ Segunda referencia inventada.

5.3 Texto con ligaduras en contexto

La diferencia entre texto con y sin ligaduras Unicode:

Sin ligaduras: "The effect of different fonts on legibility is difficult to quantify."
Con ligaduras: "The effect of different fonts on legibility is difficult to quantify."

Nótese que ﬀ (U+FB00) y ﬃ (U+FB03) son caracteres únicos, mientras que en el texto sin ligaduras son dos caracteres separados: f+f y f+f+i.

5.4 Texto multilingüe con comillas regionales

Español (comillas angulares): «Hola, ¿cómo estás?»
Francés (comillas angulares con espacio): « Bonjour, comment allez-vous ? »
Alemán (comillas bajas-altas): „Guten Tag, wie geht es Ihnen?"
Inglés (comillas altas): "Hello, how are you?"
Finés (comillas iguales): "Hei, kuinka voit?"

5.5 Uso del guión, raya y guión medio en contexto

El guión (-) une palabras: teórico-práctico, físico-matemático.
El guión medio (–) indica rangos: páginas 10–20, años 1900–1950.
La raya (—) introduce incisos: El libro —publicado en 1984— cambió todo.

La línea horizontal (—) también se usa para diálogos en algunos estilos:

— ¿Qué piensas? —preguntó el maestro.

SECCIÓN 6 — CASOS DIFÍCILES

6.1 Caracteres visualmente similares

Par 1: « (U+00AB) vs. << (dos menores que ASCII)

Par 2: » (U+00BB) vs. >> (dos mayores que ASCII)

Par 3: " (U+201C) vs. " (U+0022, comilla recta ASCII)

Par 4: " (U+201D) vs. " (U+0022, comilla recta ASCII)

Par 5: — (U+2014, raya) vs. - (U+002D, guión ASCII)

Par 6: – (U+2013, guión medio) vs. - (U+002D, guión ASCII)

Par 7: … (U+2026, elipsis) vs. ... (tres puntos ASCII)

Par 8: ' (U+2019, apóstrofe tipográfico) vs. ' (U+0027, ASCII)

Par 9: · (U+00B7, punto medio) vs. . (U+002E, punto ASCII)

Par 10: ° (U+00B0, grado) vs. º (U+00BA, ordinal masculino)

6.2 Secuencia densa de símbolos tipográficos

«¡Imposible! —exclamó—. "Nunca lo hubiéramos pensado…"»

Contiene: « (U+00AB), ¡ (U+00A1), — (U+2014), " (U+201C), … (U+2026), " (U+201D), » (U+00BB)

6.3 Comillas anidadas de diferentes tipos

«El texto decía: "Las 'palabras clave' son fundamentales."»

Tres niveles: « » (exterior) → " " (medio) → ' ' (interior)

6.4 Ligaduras en secuencia

El texto "difficult, official, affluent, efficient" contiene múltiples oportunidades de ligadura: fi, ffi, fl, ffi.

Con ligaduras Unicode: "difficult, official, affluent, efficient"

6.5 Espacios especiales invisibles

El espacio de no separación (U+00A0) entre "Sr." y "García" impide el salto de línea: Sr. García (aunque visualmente indistinguible en este documento).

El espacio fino (U+2009) se usa antes de signos de puntuación en francés. Ejemplo: « Bonjour » (con espacios finos antes de « y »).

6.6 Compatibilidad de diacríticos

Español estándar con tildes: á é í ó ú ü ñ
Mayúsculas: Á É Í Ó Ú Ü Ñ
Combinaciones: álgebra, ñoño, lingüístico, periódico, cañón

Algunos parsers normalizan las tildes o las eliminan. Este es uno de los casos de prueba más importantes para texto en español.

SECCIÓN 7 — TEXTO DE CONTROL FINAL

La tipografía es el arte invisible: cuando está bien hecha, no se nota. Un

texto bien tipografiado guía al lector sin que este sea consciente de las decisiones tipográficas. Las comillas, los guiones, los puntos suspensivos y los espacios especiales contribuyen a esa experiencia de lectura fluida.

Los sistemas de procesamiento de texto deben tratar estos caracteres con el mismo cuidado que cualquier otro carácter significativo. La sustitución de una raya (—) por un guión (-) o de unos puntos suspensivos (…) por tres puntos separados (...) puede parecer trivial, pero altera el texto original de formas que pueden ser relevantes para la recuperación de información.

Este texto final sirve como control para verificar que el parser no degrada el texto convencional con diacríticos españoles: álgebra, ñoño, lingüístico, periódico, cañón, corazón, tradición, música, éxito.