EL FALLO NO ESTÁ EN EL MODELO. ESTÁ EN LA INGESTA.



¿QUÉ PASA CUANDO RAG PROCESA PAPERS MATEMÁTICOS?

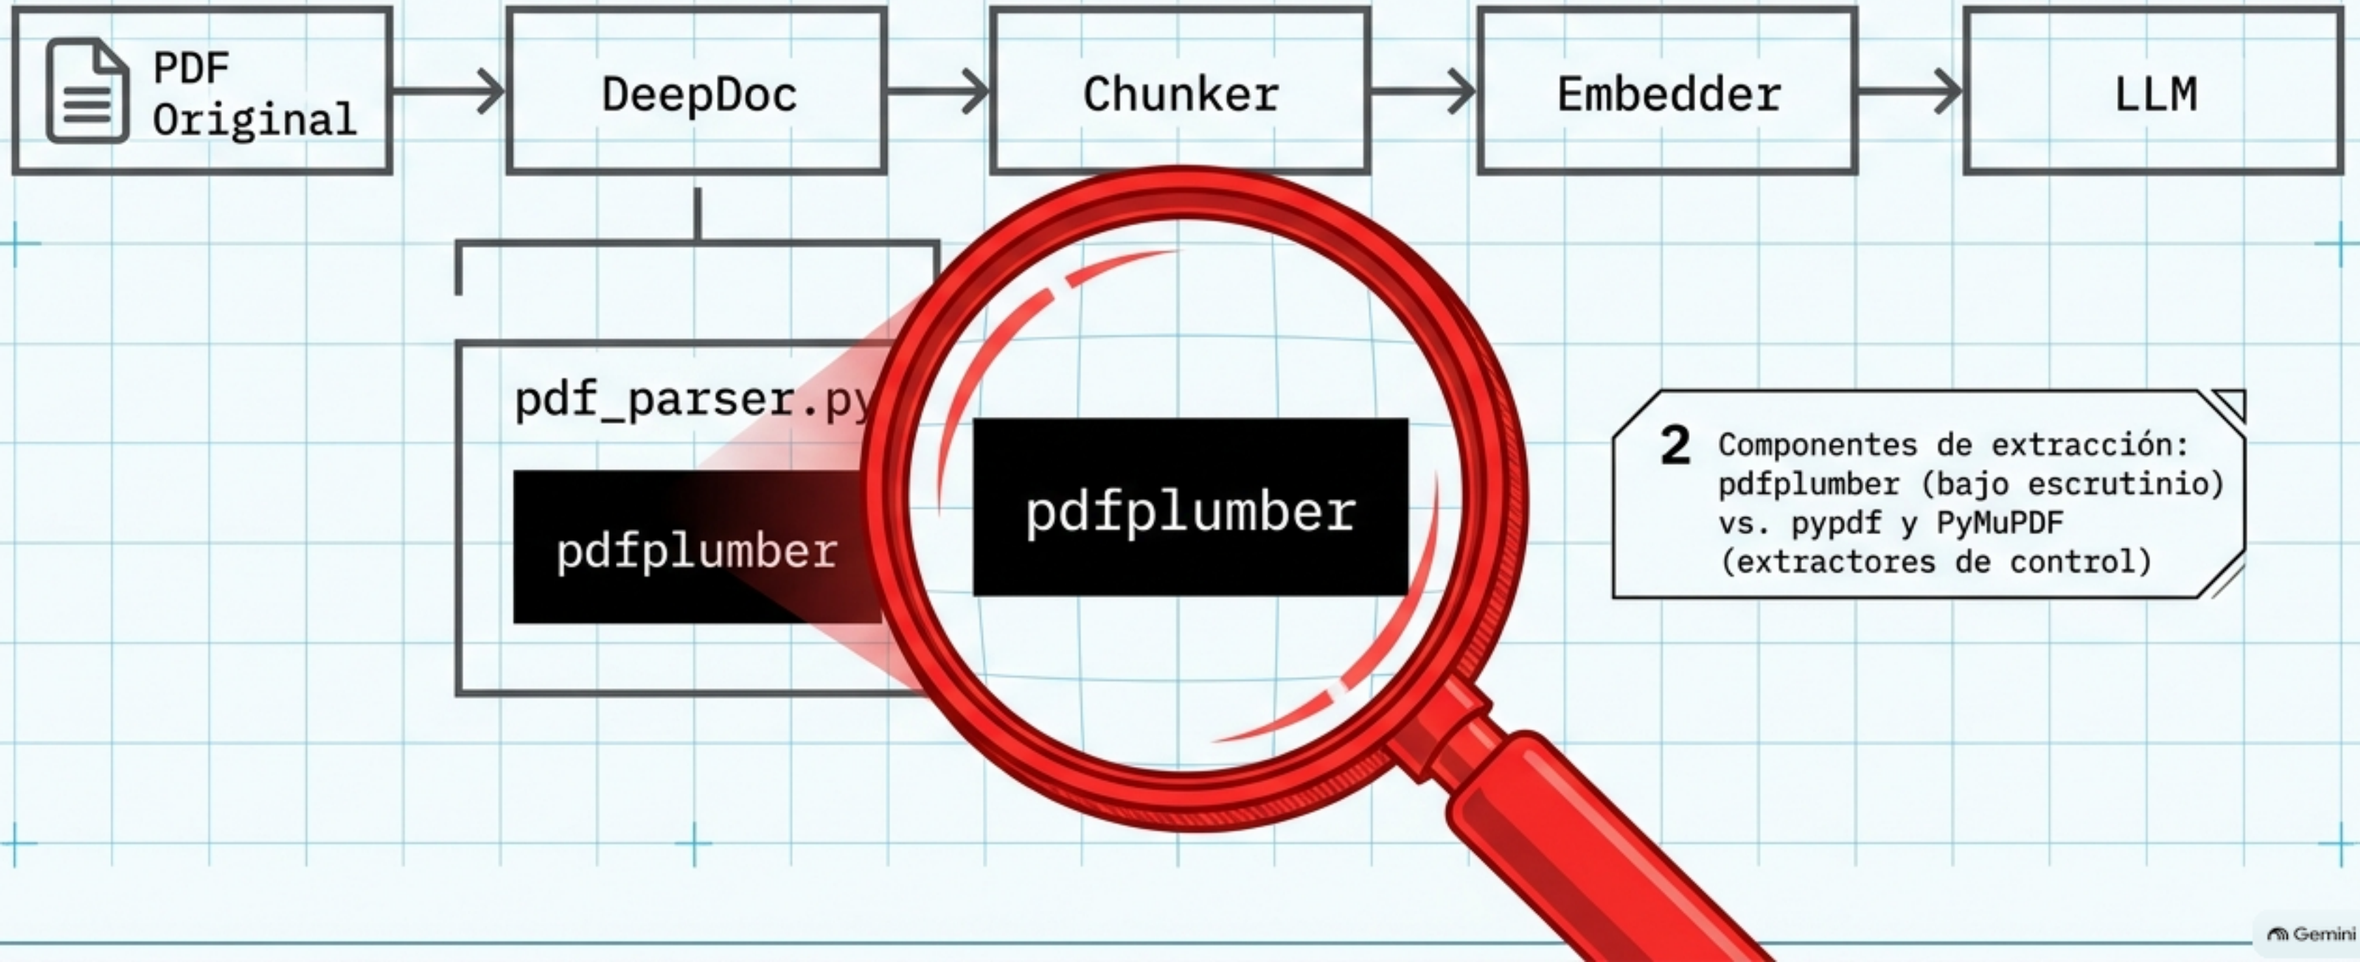


Hipótesis: Cuando el LLM falla al razonar con matemáticas en un sistema RAG, el error no es de inferencia. La ecuación fue destruida silenciosamente mucho antes de llegar a la base de datos vectorial.

Gemini Notebook

El ecosistema bajo auditoría técnica (RAGFlow & DeepDoc)

1 Etiqueta de sistema: RAGFlow / DeepDoc (Stack Open Source)

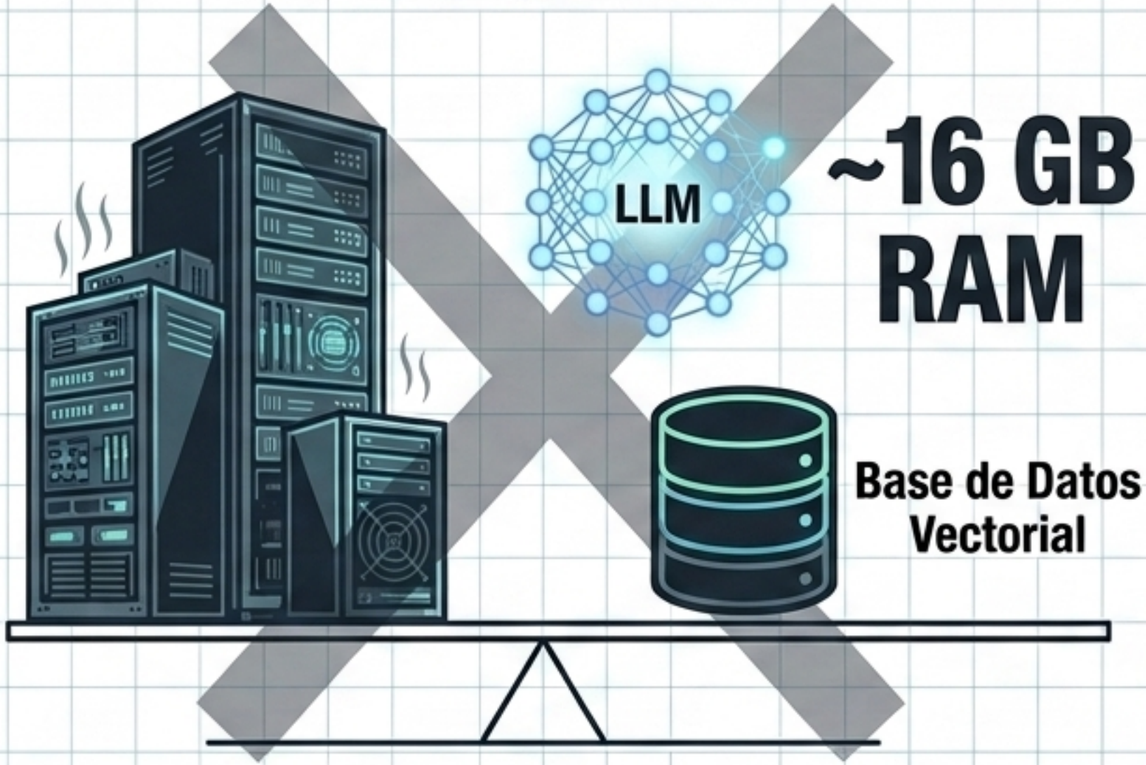


2 Componentes de extracción: pdfplumber (bajo escrutinio) vs. pypdf y PyMuPDF (extractores de control)

Gemini Notebook

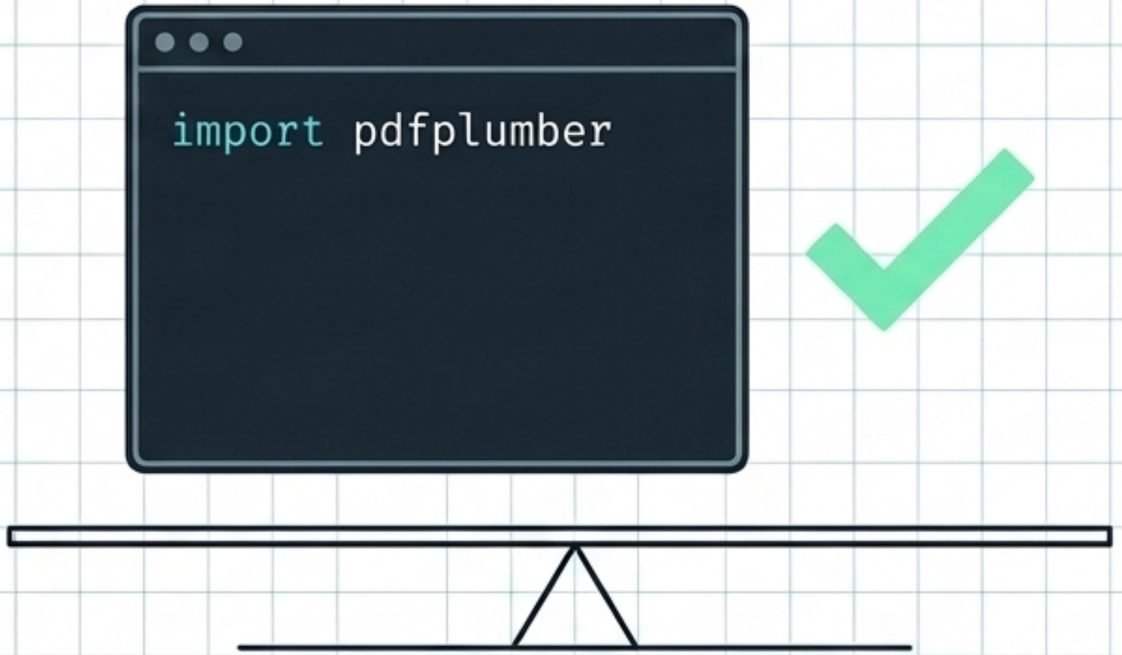
Aislamiento del entorno

Ruido/Fricción



Simular el sistema completo introduce ruido semántico y fricción de infraestructura.

Aislamiento/Precisión



Entorno Python encapsulado. Autónomo, sin LLM y sin indexación.

Rationale: Replicamos el parser subyacente (pdfminer.six) en un entorno de laboratorio aislando el punto exacto de extracción para rastrear la pérdida de datos.

Gemini Notebook

Triangulación de la verdad matemática (Metodología)

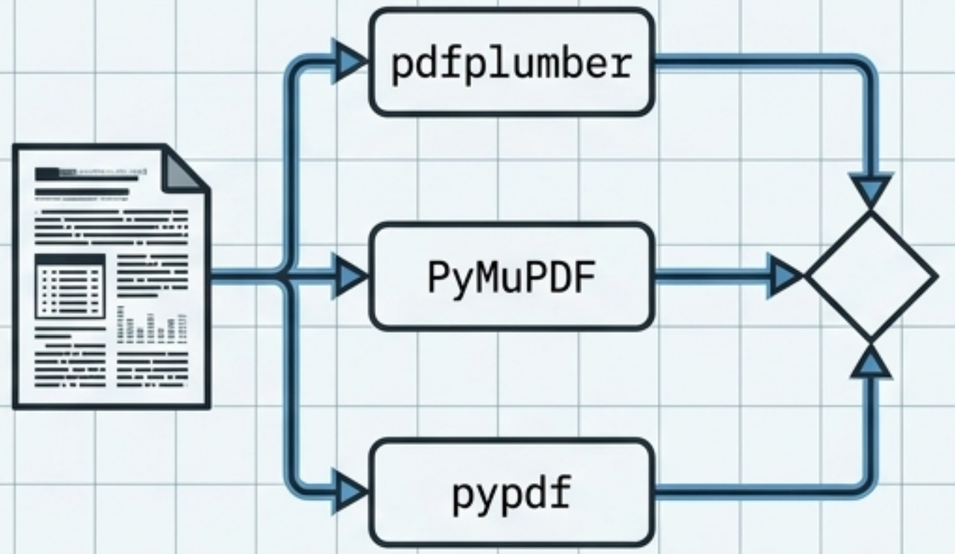
CPR (Char Preservation Rate)



Usado para PDFs sintéticos.
Mide el % exacto de símbolos recuperados frente al código fuente.

Ground truth 100% conocido.

EAR (Extractor Agreement Rate)



Usado para papers reales.
Si los tres extractores independientes no coinciden en el conteo de un símbolo, se marca una discrepancia.
Audita sin etiquetado manual.

Proxy de verdad por consenso.

Gemini Notebook

El techo teórico: El bug no existe en PDFs ideales

Matemática
Éxito: 100% CPR

Lógica
Éxito: 100% CPR

Física
Éxito: 100% CPR

100%

Química
Éxito: 100% CPR

Música
Éxito: 100% CPR

Literatura
Éxito: 100% CPR

test_synthetic_pdf.py

```python
from reportlab.pdfgen import canvas

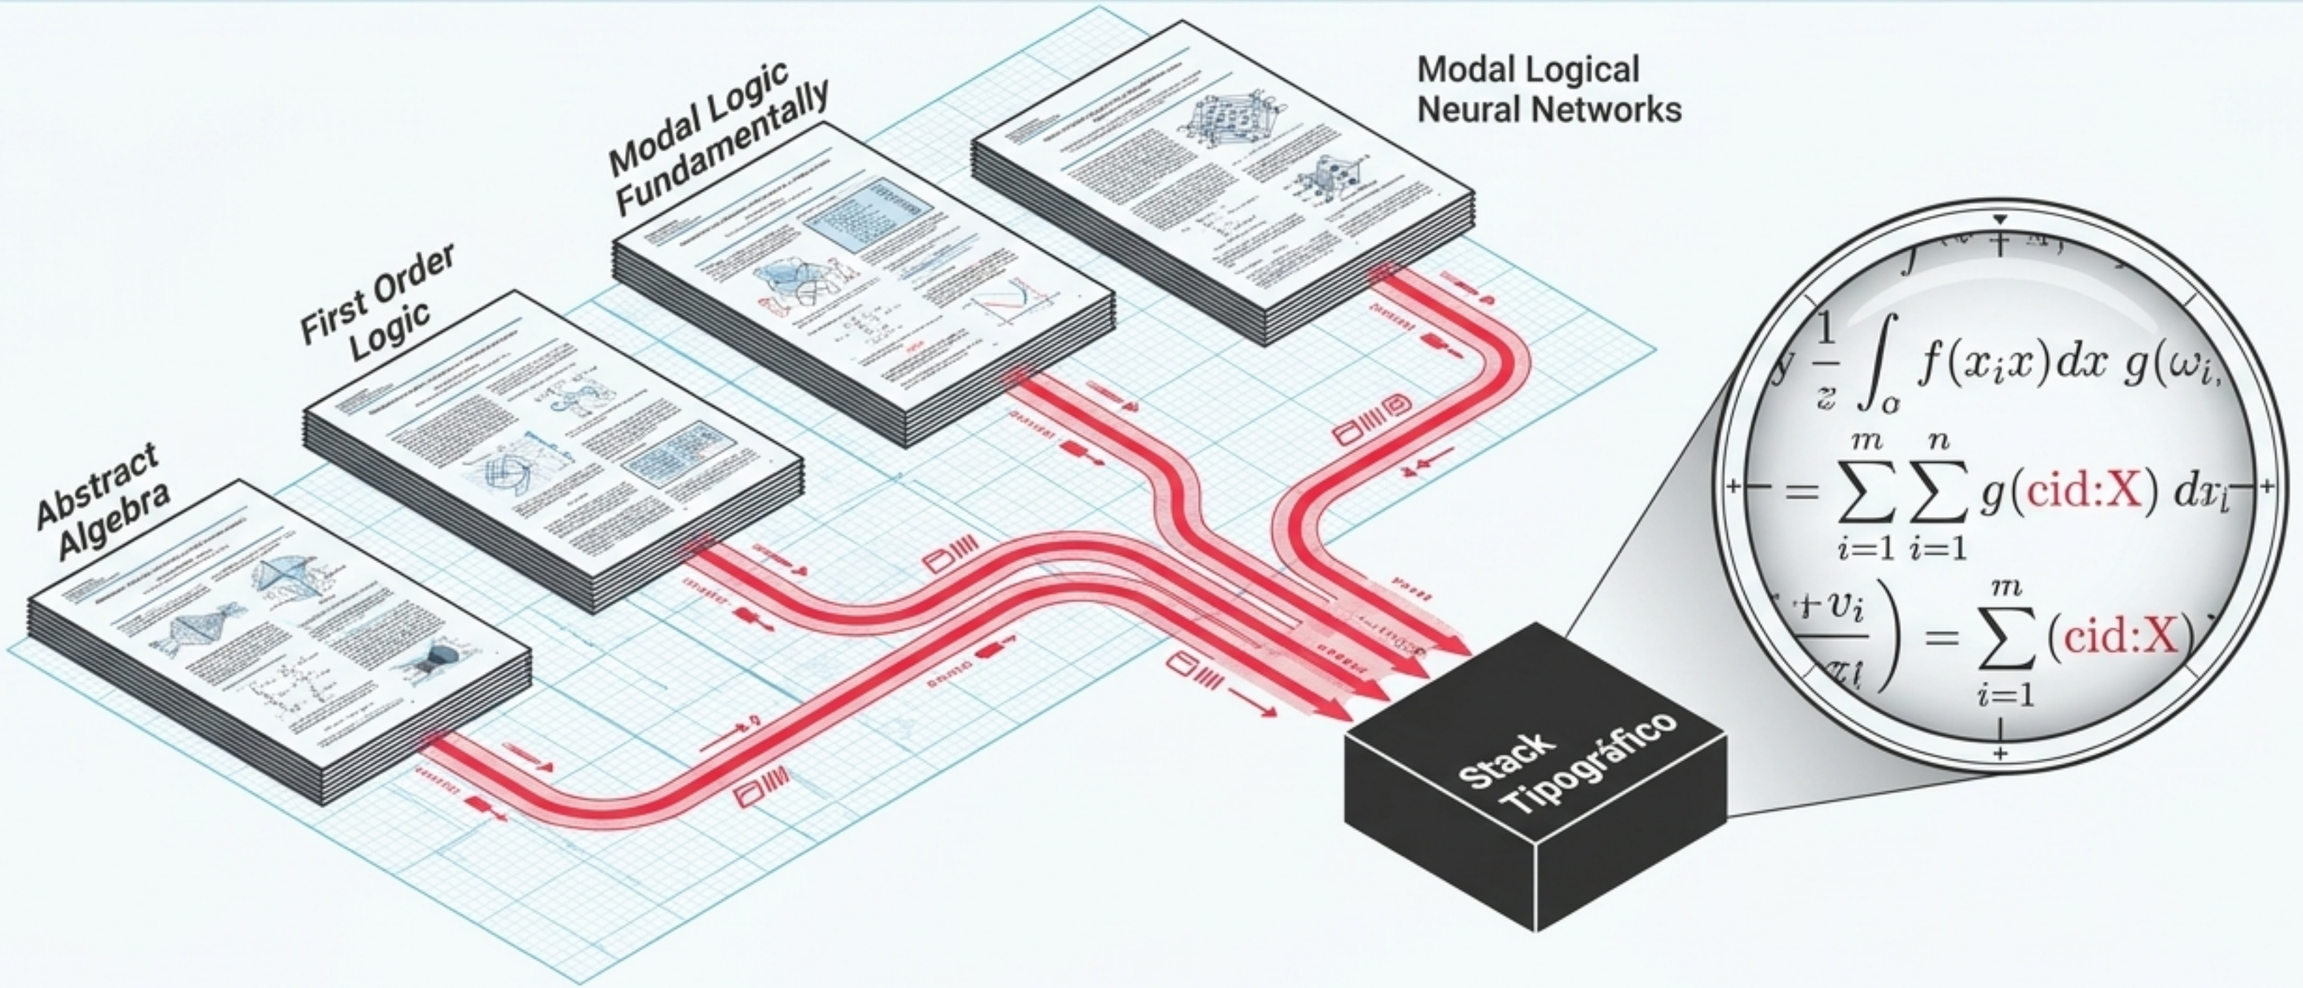

c = canvas.Canvas('synthetic_math.pdf')
c.drawString(100, 100, 'Σ (x+y) = 100')
```

Código mínimo para generar PDF ideal

Insight destacado: En este entorno ideal y artificial, el sistema funciona perfectamente (100% CPR). Esta falta de errores demuestra por qué las pruebas adicionales y más realistas con PDFs de papers académicos reales son cruciales para revelar fallos.

Gemini Notebook

El ecosistema académico y la variable conflictiva



La Variable Común: Todos los documentos están renderizados en LaTeX.

El Detonante: El uso de fuentes de la familia Computer Modern — el estándar absoluto de la publicación matemática desde los 80s.

Gemini Notebook

MÉTODO DE MEDICIÓN: EAR (**Extractor** Agreement Rate)

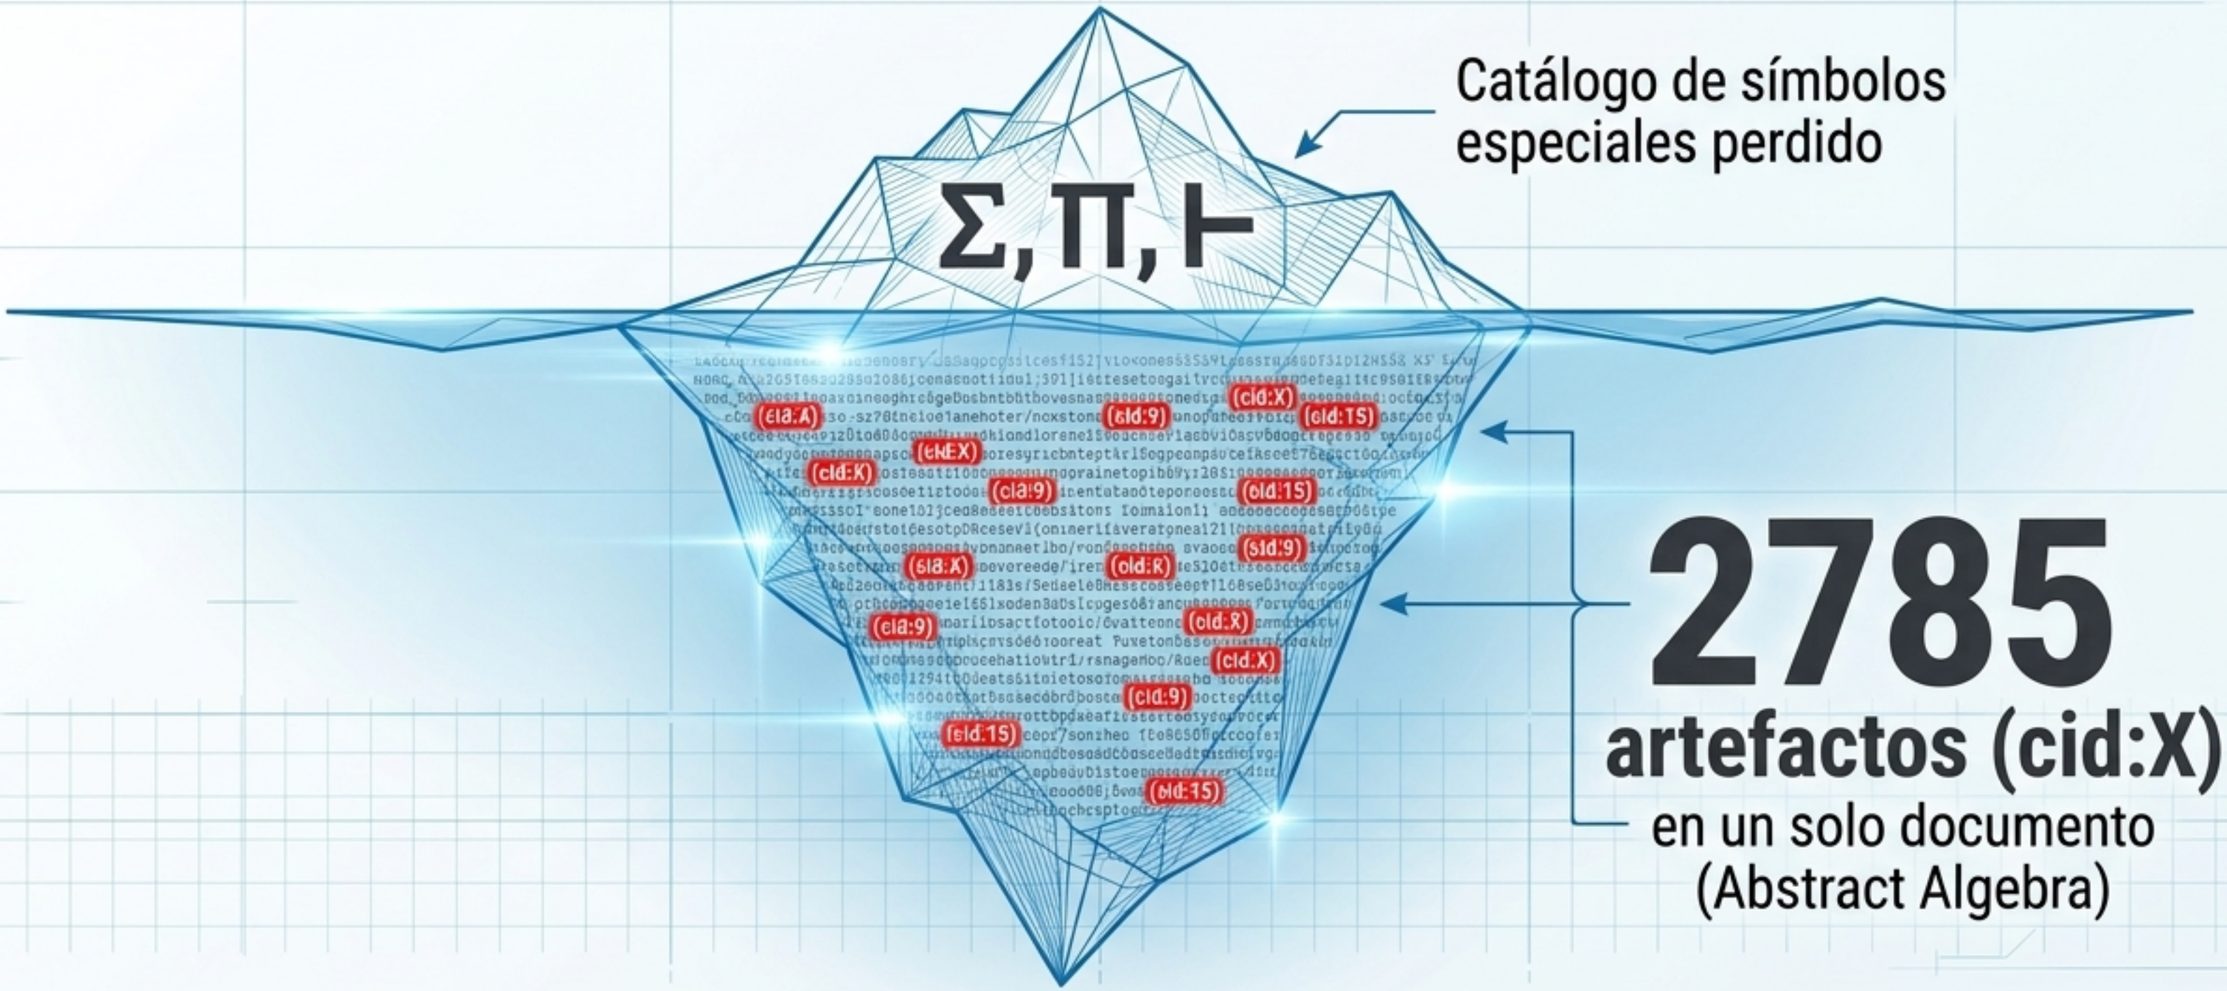
Ante la imposibilidad de contar manualmente miles de símbolos (ground truth) en papers reales, se diseñó la **Tasa de Acuerdo entre Extractores (EAR)**.

Se procesa el mismo documento con 3 librerías independientes (pdfplumber, pypdf, PyMuPDF). Si las tres no coinciden exactamente en el conteo final de un símbolo, el EAR baja del 100%, evidenciando un fallo en la extracción.

Esta triangulación nos permite auditar automáticamente el colapso de **pdfplumber** (motor de **DeepDoc**) sin intervención humana.

Gemini Notebook

La magnitud oculta de la fuga silenciosa



El hallazgo: El problema no se limita a los símbolos especiales. Fuentes enteras del texto ordinario están afectadas por la corrupción de extracción, llenando la base vectorial de ruido invisible.

Gemini Notebook

Autopsia línea a línea: Taxonomía de la corrupción

EL HILO DE ARIADNA: EL ARTEFACTO RESIDUAL

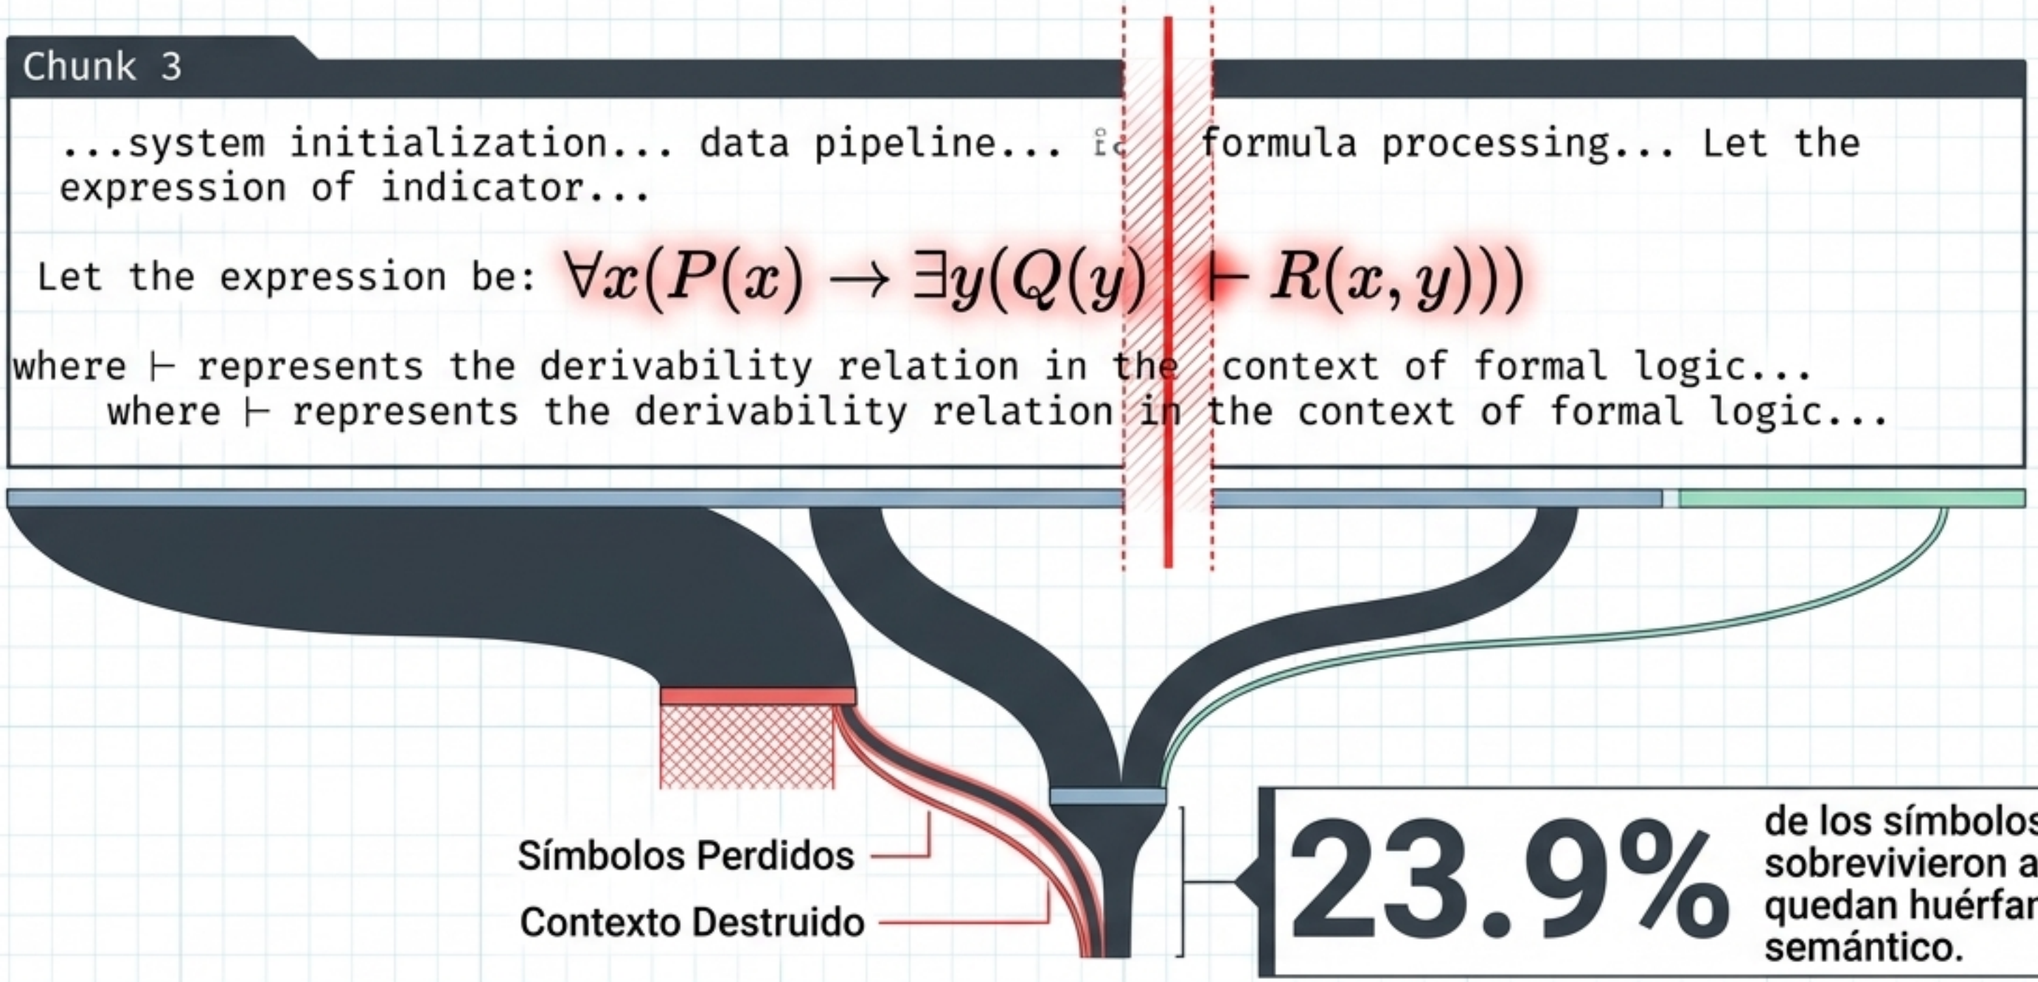
El parser falla, pero no lo hace en silencio. Al no poder resolver un símbolo, escupe su ID interno: **el marcador (cid:X)**. Esta "huella" contamina el texto, pero irónicamente es nuestra salvación: con el diccionario de fuentes adecuado, podemos rastrear este ID **y reconstruir determinísticamente** el símbolo original.

⚠ EL PUNTO CIEGO: LA OMISIÓN SILENCIOSA PURA

Existe un riesgo teórico aún mayor: que el parser silencie el glifo por completo sin emitir el marcador (cid:X). En este escenario de pérdida total, la recuperación determinística es imposible, forzando el uso de modelos probabilísticos (LLMs/SLMs) para intentar adivinar el símbolo faltante basándose puramente en el contexto matemático.

Gemini Notebook

La doble pérdida: El impacto del chunking ciego



23.9% de los símbolos ⊢ que SÍ sobrevivieron a la extracción quedan huérfanos de contexto semántico.

↘ Insight: RAGFlow aplica un chunking fijo (~2000 caracteres). Esta es una **doble pérdida independiente y acumulativa** que **condena al texto matemático al olvido** en el **retrieval**, incluso si la extracción inicial fue exitosa.

Gemini Notebook

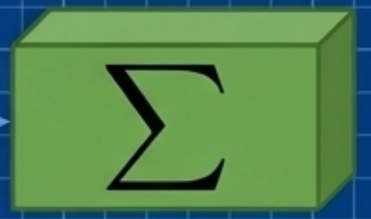
La causa raíz: El choque de diccionarios de fuente

El punto de partida: "Fuente CFF Type1"

A la izquierda, tenemos el bloque gris. Cuando un documento académico se compila con LaTeX, las fórmulas matemálicas suelen usar fuentes de la familia Computer Modern. Técnicamente, estas fuentes se incrustan en el PDF con el formato CFF Type1. Aquí es donde nace el conflicto.

El camino superior (El éxito: pypdf)

pypdf



Cuando la libreria **pypdf** se encuentra con un carácter de esta fuente, detecta que hay un diccionario incrustado en el PDF llamado **/ToUnicode CMap**. Este diccionario es básicamente una tabla de traducción que dice: "Si ves el glifo intemo número 9, debes traducirlo al carácter **Unicode U+2211 (Sumatoria)**". Al respetar esta tabla, pypdf logra extraer el simbolo ∑ correctamente (el bloque verde).

El camino inferior (El fallo: pdfminer.six)

pdfminer.six



pdfminer.six (que es el motor que usa RAGFlow/DeepDoc) toma el camino equivocado. Por un bug en su diseño, cuando ve una fuente CFF Type1 que tiene declarado un encoding base (en este caso, **/MacRomanEncoding**), ignora completamente el diccionario **/ToUnicode CMap** y aplica el MacRoman directamente. Como el glifo 9 no tiene sentido matemático en MacRoman, el parser se "rompe" y escupe el ID del glifo crudo: **(cid:9)** (representado por el ladrillo rojo roto). El simbolo desaparece y en su lugar queda este "artefacto residual" o "huella".

"El PDF contiene TODA la información correcta...
¡No es un fallo de OCR! Es un bug determinístico."

Gemini Notebook

Zonas de intervención arquitectónica



Punto Óptimo de Intervención: Post-extracción, pre-chunking.

Por qué aquí: En este espacio transicional, el PDF original (y su código de fuente) todavía está disponible, y el texto aún no ha sido fragmentado ni destruido permanentemente.

Gemini Notebook

Matriz de intervención determin’ística (Fix Fuerte)

Opción C: Parche pdfminer.six (PR)



Modificar el núcleo open source. La ambigüedad tipográfica requiere soluciones que no destruyan el layout pero resuelvan la prioridad del diccionario de fuentes.

Alternativas (Fallback/Otros):

Opción A: Hybrid Fallback (pypdf)

Baja Invasividad, Baja Complejidad, Alta Cobertura. Usa pypdf solo en páginas con (cid:X).

Opción B: Post-procesador fonttools

Baja Invasividad, Media Complejidad, Limitada Cobertura. Reemplazo vía lectura secundaria de CMap.

Gemini Notebook

Rutas de recuperación probabilística (ML/SLM)

Cuando ya perdimos la guerra determinística. El PDF original se ha perdido. Solo existe el chunk corrupto. Ya no se pueden consultar diccionarios de fuentes; hay que adivinar probabilísticamente usando Machine Learning.



D1: LLM Corrector de Contexto

La solución "fácil". Pasar el texto roto a un modelo gigante (GPT-4, Claude) para arreglarlo.

Problema: Alta flexibilidad, pero altísimo riesgo de **alucinación matemática**. Una alucinación destruye el valor del documento.



D2: Clasificador ML (Machine Learning tradicional)

Entrenar **modelo estadístico** (ej. Random Forest) sobre el corpus de 2785 artefactos. Mira el contexto (5 palabras antes/después) para predecir el símbolo Unicode.

Problema: Solo sirve para sustituciones. No puede arreglar estructuras rotas u omisiones.



D3: SLM Seq2Seq (Small Language Model / Sequence-to-Sequence)

Arquitectura para "**traducir de Matemáticas Corruptas a Matemáticas Limpias**" (T5, BART). Rápidos y entrenables para tareas específicas.

El "Superpoder" de nuestra investigación: **Dataset Gratuito**. **Generación automática de pares de entrenamiento** (Texto Malo / Texto Bueno) alineando salidas de pdfplumber y pypdf.

Input (Malo): "$p\ (x+y)p = x_i^i y^{p-i}\ i \ominus 0 \leq i \leq p$".
Target (Bueno): "$(x+y)p = \sum_{0 \leq i \leq p}$"

Gemini Notebook